

CENTRO UNIVERSITÁRIO DA FUNDAÇÃO ASSIS GURGACZ
ENGENHARIA DE SOFTWARE

**PREDIÇÃO DE ATRASOS NA ENTREGA DE PEDIDOS EM E-COMMERCE: UM
ESTUDO COMPARATIVO ENTRE ALGORITMOS DE MACHINE LEARNING**

Murilo Wolff Klug

Cascavel — PR

2026

Murilo Wolff Klug

**PREDIÇÃO DE ATRASOS NA ENTREGA DE PEDIDOS EM E-COMMERCE: UM
ESTUDO COMPARATIVO ENTRE ALGORITMOS DE MACHINE LEARNING**

Artigo apresentado como requisito
parcial para aprovação na disciplina de
Projeto de Mineração de Dados, do Curso
de Engenharia de Software do Centro
Universitário da Fundação Assis
Gurgacz.

Professor: Prof. Pedro Henrique De Avila
Tonin

Cascavel — PR

2026

RESUMO

Título: Predição de Atrasos na Entrega de Pedidos em E-Commerce: Um Estudo Comparativo entre Algoritmos de Machine Learning

Este artigo apresenta um estudo comparativo de três algoritmos de aprendizado de máquina — Regressão Logística, Random Forest e HistGradientBoosting — aplicados à predição de atrasos em entregas do e-commerce brasileiro. O corpus utilizado é o Brazilian E-Commerce Public Dataset da Olist, com 99.441 pedidos registrados entre setembro de 2016 e outubro de 2018. A pesquisa seguiu a metodologia CRISP-DM com divisão temporal de treino/teste para evitar vazamento de dados, e a imputação de valores ausentes baseou-se exclusivamente nas medianas do conjunto de treinamento. A engenharia de atributos incorporou a distância Haversine entre vendedor e cliente, variáveis temporais e características físicas dos produtos. O desbalanceamento de classes — 6,59% de pedidos com atraso — foi tratado com SMOTE integrado a um pipeline científico. Os resultados indicam sinal preditivo fraco nas variáveis estáticas disponíveis no momento da compra: a Regressão Logística obteve o maior recall (0,2478) e o HistGradientBoosting registrou o maior AUC-ROC (0,5932). Conclui-se que os atrasos decorrem principalmente de fatores operacionais dinâmicos ausentes do dataset, e o estudo oferece uma baseline metodologicamente rigorosa para trabalhos futuros.

Palavras-chave: aprendizado de máquina; Random Forest; SMOTE; CRISP-DM; e-commerce; predição de atrasos; desequilíbrio de classes; Python.

ABSTRACT

Title: Prediction of Delivery Delays in E-Commerce: A Comparative Study of Machine Learning Algorithms

This paper presents a comparative study of three machine learning algorithms — Logistic Regression, Random Forest, and HistGradientBoosting — applied to the prediction of late deliveries in Brazilian e-commerce. The dataset used is the Brazilian E-Commerce Public Dataset from Olist, comprising 99,441 orders recorded between September 2016 and October 2018. The research followed the CRISP-DM methodology with a temporal train/test split to prevent data leakage, and missing value imputation was based solely on training set medians. Feature engineering included the Haversine distance between seller and customer, temporal variables, and physical product attributes. Class imbalance — only 6.59% of orders are delayed — was addressed with SMOTE integrated within a scientific pipeline. Results show weak predictive signal in the static variables available at purchase time: Logistic Regression achieved the highest recall (0.2478) and HistGradientBoosting recorded the highest AUC-ROC (0.5932). Delivery delays are driven primarily by dynamic operational factors absent from the dataset, and this study provides a methodologically rigorous baseline for future research.

Keywords: machine learning; Random Forest; SMOTE; CRISP-DM; e-commerce; delivery delay prediction; class imbalance; Python.

SUMÁRIO

1 INTRODUÇÃO	4
2 FUNDAMENTAÇÃO TEÓRICA	4
2.1 Mineração de Dados e Classificação Binária	4
2.2 Metodologia CRISP-DM	5
2.3 Algoritmos de Aprendizado de Máquina	5
2.4 Tratamento de Desbalanceamento: SMOTE	5
2.5 Distância Haversine	5
3 METODOLOGIA	5
3.1 Entendimento do Negócio	5
3.2 Entendimento dos Dados	6
3.3 Preparação dos Dados e Engenharia de Atributos	6
3.4 Divisão Treino/Teste	7
4 IMPLEMENTAÇÃO COM PYTHON	7
4.1 Bibliotecas Utilizadas	7
4.2 Pipeline Científico	8
4.3 Implementação da Distância Haversine	8

5 RESULTADOS E DISCUSSÃO	
.....	8
5.1 Métricas de Avaliação Adotadas	
.....	8
5.2 Desempenho Comparativo dos Algoritmos	
.....	8
5.3 Análise dos Resultados por Algoritmo	
.....	9
5.4 Discussão: Poder Preditivo das Variáveis Disponíveis	
.....	9
5.5 Decisões Metodológicas e Correções Aplicadas	
.....	10
6 CONCLUSÃO	
.....	10
REFERÊNCIAS	
.....	11

1 INTRODUÇÃO

O crescimento do comércio eletrônico brasileiro nas últimas décadas tornou a logística um elemento central para a experiência do consumidor. Atrasos na entrega são a principal causa de avaliações negativas e pedidos de reembolso no varejo digital (SEBRAE, 2022). Identificar preventivamente os pedidos com maior risco de atraso, ainda no momento da confirmação da compra, permite à operação agir com antecedência: priorizar o despacho, renegociar prazos com transportadoras ou avisar o cliente antes que o problema se concretize.

A predição de eventos raros em bases desbalanceadas é um problema recorrente em mineração de dados. Quando a classe de interesse representa menos de 10% das observações, métricas convencionais como a acurácia tornam-se enganosas, e os algoritmos tendem a ignorar a classe minoritária (CHAWLA et al., 2002). O tratamento adequado desse desbalanceamento, combinado à seleção criteriosa de atributos e a uma validação metodologicamente sólida, é condição necessária para que o modelo tenha utilidade prática.

Este trabalho tem três objetivos: construir um pipeline de aprendizado de máquina seguindo o processo CRISP-DM (WIRTH; HIPPE, 2000) para predição de entregas atrasadas no e-commerce brasileiro; comparar o desempenho de Regressão Logística, Random Forest e HistGradientBoosting sob protocolo experimental controlado; e avaliar o poder preditivo das variáveis disponíveis no momento da compra, apontando limitações e diretrizes para trabalhos futuros.

O corpus utilizado é o Brazilian E-Commerce Public Dataset disponibilizado pela Olist no Kaggle, com cobertura de setembro de 2016 a outubro de 2018. Todo o desenvolvimento foi feito em Python, com as bibliotecas pandas, scikit-learn e imbalanced-learn, detalhadas na seção 4.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Mineração de Dados e Classificação Binária

Mineração de dados consiste na extração de padrões não triviais e potencialmente úteis a partir de grandes bases de dados (HAN; KAMBER; PEI, 2011). Entre as tarefas de mineração, a classificação aprende uma função que mapeia instâncias a categorias predefinidas, substituindo regras heurísticas por modelos calibrados sobre dados históricos.

A predição de atrasos configura um problema de classificação binária: a partir dos atributos de um pedido, o modelo deve determinar se a entrega ocorrerá após a data estimada (classe positiva, alvo = 1) ou dentro do prazo (classe negativa, alvo = 0). A baixa frequência

de atrasos — cerca de 6,59% dos pedidos — caracteriza o problema como de classes desbalanceadas, exigindo estratégias específicas de modelagem e avaliação.

2.2 Metodologia CRISP-DM

O CRISP-DM (Cross-Industry Standard Process for Data Mining) organiza projetos de mineração de dados em seis fases iterativas: Entendimento do Negócio, Entendimento dos Dados, Preparação dos Dados, Modelagem, Avaliação e Implantação (WIRTH; HIPPE, 2000). A natureza iterativa do modelo permite que conclusões obtidas em fases avançadas revisitem e refinem decisões anteriores, mantendo alinhamento entre o objetivo de negócio e as escolhas técnicas ao longo de todo o projeto.

2.3 Algoritmos de Aprendizado de Máquina

Regressão Logística: modelo linear que estima a probabilidade de pertencimento a uma classe por meio da função sigmoide aplicada a uma combinação linear dos atributos (HOSMER; LEMESHOW; STURDIVANT, 2013). É interpretável, computacionalmente eficiente e funciona como baseline em problemas de classificação. O parâmetro `class_weight='balanced'` do scikit-learn ajusta os pesos das classes de forma inversamente proporcional às suas frequências, compensando o desbalanceamento.

Random Forest: conjunto de árvores de decisão treinadas sobre amostras bootstrap do conjunto de treinamento, com seleção aleatória de atributos em cada nó (BREIMAN, 2001). A predição final resulta de votação majoritária entre as árvores. Árvores profundas garantem baixo viés; o ensemble reduz a variância. Como subproduto, o algoritmo calcula a importância de cada atributo pela redução média de impureza Gini (MDI) ou por permutação.

HistGradientBoosting: implementação de gradient boosting baseada em histogramas de valores dos atributos, inspirada no LightGBM (KE et al., 2017). Treina árvores sequencialmente, cada uma corrigindo os resíduos da anterior. Suporta nativamente valores ausentes e apresenta desempenho computacional superior ao GradientBoostingClassifier convencional em bases de médio e grande porte.

2.4 Tratamento de Desbalanceamento: SMOTE

O SMOTE (Synthetic Minority Over-sampling Technique) gera instâncias sintéticas da classe minoritária por interpolação entre observações reais e seus k vizinhos mais próximos (CHAWLA et al., 2002). A técnica amplia o espaço de decisão da classe positiva sem simplesmente replicar exemplos existentes. Neste trabalho, o SMOTE foi integrado ao pipeline com `sampling_strategy=0,3`, estabelecendo proporção de 30% de positivos no

treinamento — configuração menos agressiva que o balanceamento total, a fim de evitar a geração excessiva de exemplos sintéticos em espaço de alta dimensionalidade (FERNANDEZ et al., 2018).

2.5 Distância Haversine

A fórmula de Haversine calcula a distância em linha reta entre dois pontos na superfície terrestre a partir de coordenadas geográficas, considerando a curvatura esférica da Terra (SINNOTT, 1984). Neste estudo, ela quantifica a distância entre o ponto de origem do pedido (localização do vendedor) e o destino (localização do cliente), capturando parte da complexidade logística da rota de entrega.

3 METODOLOGIA

3.1 Entendimento do Negócio

O problema consiste em reduzir o impacto de entregas atrasadas por meio de predição antecipada. O critério de sucesso adotado é o recall da classe positiva: não identificar um atraso real gera custo maior — insatisfação do cliente, reembolsos, avaliações negativas — do que emitir um falso alarme, que demanda apenas esforço operacional preventivo.

3.2 Entendimento dos Dados

O dataset é composto por seis arquivos CSV do repositório Olist, abrangendo o ciclo completo dos pedidos: tabelas de pedidos, itens, produtos, vendedores, clientes e geolocalização. Após junção e filtragem de pedidos com status 'delivered' e data de entrega registrada, obteve-se uma base com 96.470 pedidos únicos. A Tabela 1 apresenta as características gerais do dataset após o pré-processamento.

Tabela 1 – Caracterização do dataset Olist após pré-processamento

Métrica	Valor
Total de pedidos (bruto)	99.441
Linhas após merge completo	112.650 × 29 colunas
Pedidos filtrados (delivered + data válida)	110.189
Pedidos únicos (após deduplicação por order_id)	96.470
Proporção da classe positiva (atraso = 1)	6,59%
Proporção da classe negativa (no prazo = 0)	93,41%
Mediana de antecipação (atraso_dias)	-13,0 dias
Pico mensal de atrasos	Março: 14,50% Novembro: 11,91%

Métrica	Valor
Estados com maior taxa de atraso	BA: 11,89% RJ: 11,62%

Nota: Fonte: Olist (2018). Elaborado pelo autor. $\text{atraso_dias} = \text{order_delivered_customer_date} - \text{order_estimated_delivery_date}$.

A variável-alvo foi definida como $\text{atraso} = 1$ quando $\text{order_delivered_customer_date} > \text{order_estimated_delivery_date}$; e $\text{atraso} = 0$ nos demais casos. Pedidos sem data de entrega registrada foram removidos, pois essa informação é necessária para o cálculo do alvo. O forte desbalanceamento — apenas 6,59% dos pedidos atrasam — torna a acurácia bruta uma métrica enganosa e exige estratégias específicas de modelagem (CHAWLA et al., 2002).

3.3 Preparação dos Dados e Engenharia de Atributos

Todas as 12 variáveis preditoras foram construídas exclusivamente com informações disponíveis no momento da compra, evitando vazamento de dados. Variáveis derivadas de eventos posteriores ao pedido — como a data de coleta pela transportadora ($\text{order_delivered_carrier_date}$) — foram deliberadamente excluídas. A Tabela 2 descreve os atributos utilizados.

Tabela 2 – Atributos preditores utilizados no modelo

Atributo	Tipo	Descrição
price (soma)	Contínua	Valor total do pedido (R\$)
freight_value (soma)	Contínua	Frete total pago (R\$)
product_weight_g (soma)	Contínua	Peso total do pedido (g)
volume_cm ³ (soma)	Contínua	Volume total (comp. × alt. × larg.)
distancia_km (média)	Contínua	Distância Haversine vendedor–cliente (km)
dia_semana	Discreta	Dia da semana da compra (0 = segunda, 6 = domingo)
mes	Discreta	Mês da compra — captura sazonalidade
hora	Discreta	Hora da compra (0–23)
mesmo_estado	Binária	1 se vendedor e cliente no mesmo estado
product_category_name	Categórica	Categoria do produto
customer_state	Categórica	Estado (UF) do comprador
seller_state	Categórica	Estado (UF) do vendedor

Nota: Fonte: elaborado pelo autor a partir do dataset Olist (2018).

A deduplicação por order_id , realizada via agrupamento com funções de agregação do pandas, eliminou a pseudo-replicação decorrente da granularidade por item do dataset

original. Atributos numéricos foram imputados pela mediana e normalizados com StandardScaler; atributos categóricos receberam imputação por constante e codificação OneHotEncoder com handle_unknown='ignore'.

3.4 Divisão Treino/Teste

A divisão entre os conjuntos de treinamento e teste foi realizada de forma temporal. Dividir aleatoriamente dados com dependência temporal constitui erro metodológico grave, pois permitiria ao modelo aprender com observações futuras para prever o passado, simulando capacidade preditiva inexistente em produção (BERGMEIR; HYNDMAN; KOO, 2018). O dataset foi ordenado por order_purchase_timestamp e dividido na proporção 80/20: o conjunto de treinamento abrange os 80% de pedidos mais antigos, e o conjunto de teste, os 20% mais recentes.

4 IMPLEMENTAÇÃO COM PYTHON

4.1 Bibliotecas Utilizadas

O desenvolvimento do pipeline foi realizado integralmente em Python, utilizando bibliotecas científicas consolidadas na comunidade de ciência de dados, conforme indicado na Tabela 3.

Tabela 3 – Bibliotecas Python utilizadas no projeto

Biblioteca	Módulo / Classe	Aplicação no Projeto
pandas	DataFrame, groupby, merge	Carregamento, junção e manipulação dos CSVs
NumPy	np.radians, np.sin	Cálculo vetorial da distância Haversine
scikit-learn	Pipeline, ColumnTransformer	Pipeline de pré-processamento integrado
scikit-learn	SimpleImputer, StandardScaler	Imputação e normalização de atributos numéricos
scikit-learn	OneHotEncoder	Codificação de variáveis categóricas
scikit-learn	LogisticRegression	Modelo baseline linear
scikit-learn	RandomForestClassifier	Ensemble de árvores de decisão
scikit-learn	HistGradientBoostingClassifier	Gradient boosting por histograma
scikit-learn	roc_auc_score, f1_score, recall_score	Métricas de avaliação
imbalanced-learn	ImbPipeline, SMOTE	Pipeline com balanceamento de classes

Biblioteca	Módulo / Classe	Aplicação no Projeto
joblib	dump	Serialização do pipeline para produção

Nota: Fonte: elaborado pelo autor.

4.2 Pipeline Científico

O pipeline integra pré-processamento e modelagem em um único objeto do tipo `ImbPipeline` (imbalanced-learn), garantindo que o SMOTE seja aplicado apenas sobre os dados de treinamento em cada iteração de validação cruzada. Esse procedimento previne o vazamento de instâncias sintéticas para o conjunto de avaliação, erro que inflaria artificialmente as métricas de desempenho.

4.3 Implementação da Distância Haversine

A distância geográfica entre vendedor e cliente foi calculada por meio da fórmula de Haversine, implementada como função vetorizada com NumPy para garantir eficiência computacional sobre o dataset completo. A tabela de geolocalização foi pré-agregada por CEP — com médias de latitude e longitude por prefixo postal — antes da junção com os dados de pedidos, reduzindo redundâncias e o risco de inconsistências.

5 RESULTADOS E DISCUSSÃO

5.1 Métricas de Avaliação Adotadas

Dado o forte desbalanceamento das classes, a acurácia global foi descartada como métrica principal: um classificador ingênuo que sempre prediz 'no prazo' alcançaria acurácia superior a 93% sem qualquer utilidade prática. As métricas selecionadas foram: (a) recall — proporção dos atrasos reais corretamente identificados, métrica de otimização primária; (b) precisão — proporção dos alertas emitidos que correspondem a atrasos reais; (c) F1-score — média harmônica entre precisão e recall; e (d) AUC-ROC — área sob a curva ROC, que mede a capacidade discriminativa geral do modelo independentemente do limiar de classificação.

5.2 Desempenho Comparativo dos Algoritmos

Os três algoritmos foram treinados sob o mesmo protocolo experimental — mesmos atributos, mesmo pipeline de pré-processamento e mesma divisão temporal — e avaliados sobre o conjunto de teste. Os resultados estão consolidados na Tabela 4.

Tabela 4 – Resultados comparativos dos algoritmos de aprendizado de máquina

Modelo	Acurácia	Precisão	Recall	F1-Score	AUC-ROC
Regressão Logística	0,6826	0,0451	0,2478	0,0763	0,4465
Random Forest	0,9456	0,1500	0,0059	0,0113	0,5355
HistGradientBoosting	0,9471	0,0000	0,0000	0,0000	0,5932

Nota: Fonte: elaborado pelo autor. Métricas calculadas sobre o conjunto de teste (20% dos dados, split temporal).

5.3 Análise dos Resultados por Algoritmo

Regressão Logística: obteve o maior recall (0,2478), identificando cerca de 25% dos atrasos reais. A acurácia global de 68,26% e o AUC-ROC de 0,4465 — abaixo do desempenho de um classificador aleatório (0,50) — indicam que o modelo gera muitos falsos alarmes e não generaliza adequadamente. Essa limitação decorre da incapacidade de um modelo linear capturar interações não lineares entre as variáveis geográficas e temporais.

Random Forest: apresentou a segunda maior acurácia (94,56%) e a maior precisão entre os modelos (0,1500), porém com recall próximo de zero (0,0059). Na prática, o algoritmo aprendeu a classificar sistematicamente todos os pedidos como 'no prazo', maximizando a acurácia ao custo de ignorar a classe de interesse. O AUC-ROC de 0,5355 indica algum poder discriminativo nas probabilidades estimadas, o que sugere que o ajuste do limiar de classificação, por meio da curva Precisão-Recall, poderia melhorar o recall.

HistGradientBoosting: registrou recall e F1-Score iguais a zero, indicando colapso para a classe majoritária sob o limiar padrão de 0,5. Ainda assim, apresentou o maior AUC-ROC (0,5932), evidenciando que as probabilidades estimadas possuem poder discriminativo latente — explorado pelo AUC-ROC por avaliar todos os limiares possíveis. O resultado reforça a inadequação do limiar padrão em problemas de classes desbalanceadas.

5.4 Discussão: Poder Preditivo das Variáveis Disponíveis

Os resultados indicam baixo sinal preditivo nas variáveis estáticas disponíveis no momento da compra. O atraso nas entregas não apresenta correlação forte com preço, peso ou distância geográfica no dataset da Olist. Essa constatação aponta para fatores externos e dinâmicos como principal determinante dos atrasos: eficiência operacional da transportadora, condições climáticas na rota, falhas na última milha e sobrecarga de pedidos em períodos sazonais — variáveis ausentes nas características estáticas do pedido.

A análise exploratória dos dados corrobora essa interpretação. Pedidos realizados em março (14,50% de atraso) e novembro (11,91%) — períodos de Carnaval e Black Friday, respectivamente — apresentam taxas expressivamente acima da média, o que reflete o impacto da sobrecarga operacional sobre as transportadoras. Estados com infraestrutura

logística menos desenvolvida, como Bahia (11,89%) e Rio de Janeiro (11,62%), concentram maior incidência de atrasos, independentemente das características individuais de cada pedido.

A baixa performance obtida não representa falha metodológica, mas uma característica do fenômeno estudado. A inclusão de variáveis disponíveis apenas após a compra — como a data de coleta pela transportadora — inflaria artificialmente as métricas e comprometeria a validade científica do modelo.

5.5 Decisões Metodológicas e Correções Aplicadas

A Tabela 5 resume as principais decisões metodológicas adotadas no pipeline e suas justificativas.

Tabela 5 – Decisões metodológicas adotadas no pipeline

Decisão Metodológica	Justificativa
Split temporal (80/20 por data de compra)	Dados temporais possuem autocorrelação; split aleatório simularia capacidade preditiva inexistente em produção
Mediana calculada exclusivamente no treino	Usar a mediana do dataset completo configuraria vazamento sutil de informação do conjunto de teste
SMOTE integrado ao pipeline (ImbPipeline)	Garante que instâncias sintéticas sejam geradas apenas sobre os dados de treino em cada fold de validação cruzada
sampling_strategy=0,3 (SMOTE menos agressivo)	Reduz geração de exemplos sintéticos possivelmente irrealistas em espaço de alta dimensionalidade
Exclusão de order_delivered_carrier_date	Dado disponível somente após o evento a prever; sua inclusão configuraria data leakage grave
handle_unknown='ignore' (OneHotEncoder)	Categorias não vistas no treinamento não provocam erros em dados de produção

Nota: Fonte: elaborado pelo autor.

6 CONCLUSÃO

Este trabalho construiu um pipeline de aprendizado de máquina para predição de atrasos em entregas de e-commerce, seguindo a metodologia CRISP-DM e implementando os principais cuidados para evitar vazamento de dados e viés estatístico. A comparação entre Regressão Logística, Random Forest e HistGradientBoosting sob protocolo experimental controlado mostrou que as variáveis estáticas disponíveis no momento da compra têm baixo poder preditivo para a ocorrência de atrasos.

A Regressão Logística obteve o maior recall (0,2478), identificando preventivamente cerca de 25% dos pedidos que efetivamente atrasariam. O HistGradientBoosting apresentou o

maior AUC-ROC (0,5932), indicando que, com ajuste adequado do limiar de classificação, é possível extrair maior poder discriminativo do modelo. O Random Forest, apesar da alta acurácia global, colapsou para a classe majoritária sob o limiar padrão. Em todos os casos, os valores de AUC-ROC próximos a 0,5 confirmam que os atrasos são determinados principalmente por fatores operacionais dinâmicos ausentes do dataset.

As principais contribuições deste trabalho são: a implementação de um pipeline científico com SMOTE integrado, divisão temporal e imputação restrita ao conjunto de treinamento; a engenharia de atributos com distância Haversine; e a análise comparativa multi-algoritmo com protocolo experimental padronizado.

Para trabalhos futuros, recomenda-se: a integração de dados meteorológicos históricos nas rotas de entrega, via APIs como o INMET; a incorporação de indicadores de desempenho histórico das transportadoras por rota; a exploração de modelos de aprendizado profundo para modelar o fluxo logístico como série temporal; e a otimização sistemática do limiar de classificação por meio da curva Precisão-Recall para cada algoritmo, visando maximizar o recall com restrição de precisão mínima operacional.

REFERÊNCIAS

BERGMEIR, C.; HYNDMAN, R. J.; KOO, B. A note on the validity of cross-validation for evaluating autoregressive time series prediction. **Computational Statistics & Data Analysis**, v. 120, p. 70-83, 2018.

BREIMAN, L. Random Forests. **Machine Learning**, New York, v. 45, n. 1, p. 5-32, 2001.

CHAWLA, N. V. et al. SMOTE: Synthetic Minority Over-sampling Technique. **Journal of Artificial Intelligence Research**, v. 16, p. 321-357, 2002.

FERNANDEZ, A. et al. **Learning from Imbalanced Data Sets**. Cham: Springer, 2018.

HAN, J.; KAMBER, M.; PEI, J. **Data Mining: Concepts and Techniques**. 3. ed. Waltham: Morgan Kaufmann, 2011.

HOSMER, D. W.; LEMESHOW, S.; STURDIVANT, R. X. **Applied Logistic Regression**. 3. ed. Hoboken: Wiley, 2013.

KE, G. et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. **Advances in Neural Information Processing Systems**, v. 30, 2017.

LEMAITRE, G.; NOGUEIRA, F.; ARIDAS, C. K. Imbalanced-learn: A Python Toolbox to Tackle the Curse of Imbalanced Datasets in Machine Learning. **Journal of Machine Learning Research**, v. 18, n. 17, p. 1-5, 2017.

OLIST. **Brazilian E-Commerce Public Dataset by Olist**. 2018. Disponível em: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>. Acesso em: 16 jun. 2026.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011.

SINNOTT, R. W. Virtues of the Haversine. **Sky and Telescope**, v. 68, n. 2, p. 159, 1984.

WIRTH, R.; HIPPE, J. CRISP-DM: Towards a Standard Process Model for Data Mining. In: **Proceedings of the 4th International Conference on the Practical Application of Knowledge Discovery and Data Mining**. Manchester: PKDD, 2000. p. 29-39.